

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN



ĐỒ ÁN 1

**Chủ đề: Phân tích xu hướng tiêu dùng ngành
mỹ phẩm tại Việt Nam**

Giảng viên hướng dẫn: ThS. Nguyễn Danh Tú

Sinh viên thực hiện: Nguyễn Thế Thiện

Mã số sinh viên: 20227264

Hà Nội, 6/2025

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

1. Mục tiêu và nội dung của đề án

1. Mục tiêu
2. Nội dung

2. Kết quả đạt được

- 1.
- 2.
- 3.

3. Ý thức làm việc của sinh viên

- 1.
- 2.
- 3.

Hà Nội, ngày ... tháng ... năm 2025

Giảng viên hướng dẫn

Nguyễn Danh Tú

Lời cảm ơn

Trước hết, em xin gửi lời cảm ơn sâu sắc đến giảng viên hướng dẫn của mình - Thạc sỹ Nguyễn Danh Tú đã hết mình hỗ trợ em trong quá trình học và làm đồ án 1 này. Bản thân em trong quá trình làm đồ án không ít lần gặp phải những điều lạ, không biết cũng như là có rất nhiều vướng mắc, "cổ chai" trong quá trình. Nhưng thật may vì em đã có một người thầy, hay thân thiết hơn gọi là "một người đồng hành" đã hỗ trợ em hết mình, giải đáp các thắc mắc mà em mắc phải. Mặc dù không phải lúc nào những lời giải đáp là đủ "gỡ rối" những gì ở trong đầu em. Song, nó lại là kim chỉ nam, là định hướng đúng đắn để em có thể làm và hoàn thiện đồ án 1 này. Bản thân em trong quá trình làm cũng không ít lần thể hiện sự nghi vấn, ngoài nghi về khả năng của mình cũng như là "sức nặng" của đề tài. Thế nhưng, bằng sự cố gắng của bản thân cũng như sự tận tình của thầy thì em cuối cùng đã hoàn thành đồ án 1 này. Mặc dù đồ án tính đến thời điểm hiện tại được coi là hoàn thiện, thế nhưng mà chưa thể nào là "hoàn hảo" bởi: ai cũng mắc sai lầm. Vậy nên ở đồ án này, nếu em có mắc sai lầm gì trong quá trình đánh máy hay phân tích. Em mong nhận được sự nhận xét và góp ý để có thể làm những đồ án khác hay những tài liệu khác hoàn thiện hơn.

Mặt khác, em cũng xin gửi lời cảm ơn đến các bạn làm cùng đồ án: Nhung, Dương, Đạt, Ngọc vì họ rất thân thiện và sẵn sàng trả lời những thắc mắc của em trong quá trình làm đồ án này. Một lần nữa, mình cảm ơn các cậu.

Và cũng không thể nào quên gửi lời cảm ơn đến Đại học Bách khoa Hà Nội vì đã tạo cơ hội cho em được làm việc cùng với các bạn và người thầy tận tình:
Nguyễn Danh Tú

Hà Nội, ngày ... tháng ... năm 2025

Sinh viên thực hiện

Nguyễn Thế Thiện

Tóm tắt nội dung đồ án

Đồ án tập trung vào việc phân tích xu hướng tiêu dùng của ngành hàng mỹ phẩm tại thị trường Việt Nam, một lĩnh vực có tốc độ tăng trưởng nhanh và cạnh tranh cao. Mục tiêu chính của đồ án là xây dựng một hệ thống hoàn chỉnh có khả năng tự động thu thập, xử lý và trực quan hóa dữ liệu từ các nguồn trực tuyến, nhằm cung cấp cái nhìn sâu sắc và hỗ trợ việc ra quyết định kinh doanh.

Để thực hiện mục tiêu này, đồ án đã tiến hành thu thập dữ liệu từ hai sàn thương mại điện tử lớn nhất hiện nay là **Shopee** và **Lazada**. Dữ liệu từ Lazada được lấy thông qua API Public, trong khi dữ liệu từ Shopee được thu thập bằng kỹ thuật Web Scraping với sự hỗ trợ của các thư viện Python như Selenium và BeautifulSoup. Dữ liệu thô sau khi thu thập được lưu trữ tạm thời (staging) trên SQL Server.

Quy trình **ETL (Extract - Transform - Load)** được xây dựng bằng Python, kết hợp với SQL, để tự động hóa việc trích xuất dữ liệu từ khu vực staging, làm sạch, chuẩn hóa (xử lý giá, định dạng, tên thương hiệu) và chuyển đổi dữ liệu. Dữ liệu sau khi xử lý được nạp vào một **Data Warehouse** được thiết kế theo mô hình **Snowflake Schema**, giúp tối ưu hóa khả năng lưu trữ và tốc độ truy vấn phân tích. Toàn bộ quy trình được lập lịch để chạy tự động, đảm bảo dữ liệu luôn được cập nhật.

Kết quả cuối cùng của đồ án là một hệ thống phân tích dữ liệu hoàn chỉnh. Các thông tin chi tiết về thị trường được trực quan hóa thông qua các **dashboard tương tác** xây dựng trên **Power BI**. Các dashboard này cung cấp cái nhìn tổng quan về doanh thu, số lượng sản phẩm bán ra, thị phần các thương hiệu và các xu hướng tiêu dùng nổi bật, từ đó đưa ra những phân tích giá trị cho ngành hàng mỹ phẩm.

MỤC LỤC

Lời cảm ơn	1
Lời nói đầu	2
Danh sách hình vẽ	6
1 Cơ sở lý thuyết	8
1.1 Tổng quan về Data Warehouse	8
1.1.1 Data Warehouse là gì ?	8
1.1.2 Đặc điểm của Data Warehouse	8
1.1.3 Quy trình xử lý dữ liệu trong Data Warehouse	9
1.1.4 Các mô hình tiêu biểu của Data Warehouse	9
1.1.5 Vai trò và ứng dụng	10
1.2 Tổng quan về quy trình ETL	11
1.2.1 Giới thiệu	11
1.2.2 Tổng quan về quy trình ETL	11
1.2.3 Vai trò và ứng dụng của ETL	12
1.3 Tổng quan về Web Scraping	12
1.3.1 Web Scraping là gì ?	12
1.3.2 Cách thức hoạt động	12
1.3.3 Ứng dụng của Web Scraping	13
1.3.4 Lưu ý về vấn đề pháp lý	13
1.4 Tổng quan về BI (Business Intelligence)	13
1.4.1 BI là gì ?	13
1.4.2 Vai trò và mục tiêu của BI ?	14

1.4.3	Thành phần và quy trình hoạt động của BI	14
1.4.4	Lợi ích của BI	14
2	Khảo sát đề tài	16
2.1	Khảo sát nhu cầu	16
2.1.1	Quy mô tăng trưởng thị trường mỹ phẩm tại Việt Nam . . .	16
2.1.2	Nhu cầu tiêu dùng và đặc điểm người dùng	16
2.1.3	Cạnh tranh và cơ hội	17
2.2	Khảo sát nguồn dữ liệu	17
2.3	Khảo sát các cách thức thu thập dữ liệu	18
2.4	Khảo sát các công cụ thu thập dữ liệu	19
2.5	Khảo sát các định dạng dữ liệu phổ biến	21
2.6	Khảo sát các cách lưu trữ dữ liệu	22
2.7	Khảo sát các công cụ ETL chuyên dụng	25
2.8	Khảo sát các công cụ trực quan hoá dữ liệu	26
3	Phân tích và thiết kế hệ thống	27
3.1	Cách thức thu thập dữ liệu	27
3.2	Cách thức lưu trữ dữ liệu thô	30
3.3	Phương pháp thực hiện ETL và xây dựng Data Warehouse	32
3.4	Lập lịch tự động quy trình	33
4	Xây dựng hệ thống	34
4.1	Các công nghệ sử dụng	34
4.1.1	Nguồn thu thập dữ liệu	34
4.1.2	Cách thức thu thập dữ liệu	35
4.1.3	Cách thức lưu trữ dữ liệu thô	35
4.1.4	Thực hiện ETL	36
4.1.5	Cách thức lưu trữ dữ liệu sau khi xử lý	36
4.1.6	Trực quan hoá dữ liệu	36

4.1.7	Tóm tắt hệ thống triển khai	37
4.2	Xây dựng chương trình lấy dữ liệu từ Lazada và Shopee	37
4.2.1	Chương trình lấy dữ liệu từ Lazada	37
4.2.2	Chương trình lấy dữ liệu từ Shopee	40
4.3	Xây dựng cơ chế tự động insert vào bảng chung bằng TRIGGER trong SQL Server	42
4.3.1	Trigger của bảng Lazada	42
4.3.2	Trigger của bảng Shopee	42
4.4	Xây dựng ETL Pipeline	43
4.4.1	Tổng quan	43
4.4.2	Những cài đặt người dùng cần thực hiện	43
4.4.3	Extract: extract.py	43
4.4.4	Transform: transform.py	43
4.4.5	Load: load.py	44
4.4.6	Cách hoạt động của chương trình chính	44
4.5	Lập lịch chạy tự động bằng Python	47
4.6	Thiết kế Dashboard	48
4.6.1	Phân tích tổng quan thị trường mỹ phẩm trên Shopee theo loại sản phẩm	48
4.6.2	Phân tích tổng quan thị trường mỹ phẩm trên các sàn theo khu vực	49
4.7	Toàn bộ code của đề án	49
5	Kết luận	50
5.1	Kết quả đề án	50
5.2	Kỹ năng đạt được	50
5.3	Hướng phát triển tương lai	51
	Tài liệu tham khảo	52

Danh sách hình vẽ

1.1.1 Ví dụ về star schema	9
1.1.2 Snowflake Schema	10
1.2.1 ETL Pipeline	11
1.4.1 BI là gì ?	14
2.2.1 Statista là nền tảng dữ liệu và thông tin kinh doanh toàn cầu . . .	17
2.2.2 Các sàn thương mại điện tử phổ biến tại Việt Nam	18
2.3.1 So sánh các cách thức thu thập dữ liệu	19
2.4.1 Google Form để khảo sát dữ liệu	20
2.4.2 EcomHeat	20
2.4.3 Cào dữ liệu web bằng BeautifulSoup	21
2.6.1 File Excel được sử dụng để lưu trữ dữ liệu	22
2.6.2 SQL để lưu trữ dữ liệu lớn	23
2.6.3 Nền tảng lưu trữ dữ liệu đám mây như Google Cloud	24
2.6.4 Bảng so sánh các công cụ lưu trữ dữ liệu	24
2.7.1 Bảng so sánh các công cụ ETL	25
2.8.1 Bảng so sánh các công cụ trực quan hóa dữ liệu	26
3.1.1 Captcha Shopee	29
3.3.1 Mô hình ROLAP	32
3.3.2 Snowflake Schema	33
4.1.1 Shopee và Lazada là hai nền tảng lớn	34
4.1.2 SQL Server để lưu trữ dữ liệu thô	35

4.1.3 Kết hợp python với sql trong quá trình ETL	36
4.1.4 Power BI	36
4.1.5 Tóm tắt hệ thống triển khai	37
4.2.1 Sơ đồ khối cho chương trình lấy dữ liệu Lazada	39
4.2.2 Sơ đồ khối cho chương trình Shopee	41
4.3.1 Trigger của bảng Lazada	42
4.3.2 Trigger của bảng Shopee	42
4.4.1 Sơ đồ khối cho ETL	46
4.6.1 Dashboard 1	48
4.6.2 Dashboard 2	49

Chương 1

Cơ sở lý thuyết

1.1 Tổng quan về Data Warehouse

1.1.1 Data Warehouse là gì ?

Data Warehouse (Kho dữ liệu) là một hệ thống lưu trữ dữ liệu tập trung, được thiết kế để thu thập, lưu trữ và quản lý dữ liệu từ nhiều nguồn khác nhau như phần mềm bán hàng, kế toán, nhân sự, hệ thống giao dịch và các cơ sở dữ liệu quan hệ. Mục tiêu chính của Data Warehouse là hỗ trợ quá trình phân tích dữ liệu và ra quyết định kinh doanh bằng cách cung cấp một nền tảng thống nhất, nơi dữ liệu được chuẩn hóa, tổ chức theo chủ đề và lưu trữ có cấu trúc rõ ràng

1.1.2 Đặc điểm của Data Warehouse

Đặc điểm chính của Data Warehouse

- Hướng chủ đề (Subject-Oriented): Dữ liệu được tổ chức theo các chủ đề hoặc lĩnh vực cụ thể như bán hàng, tài chính, nhân sự để phục vụ phân tích chuyên sâu.
- Tích hợp (Integrated): Dữ liệu từ nhiều nguồn khác nhau được tổng hợp, chuẩn hóa và hợp nhất thành một cấu trúc chung, giúp tạo ra cái nhìn toàn diện về hoạt động doanh nghiệp.
- Bất biến (Non-volatile): Dữ liệu trong kho không bị thay đổi thường xuyên mà được cập nhật theo chu kỳ, giữ lại lịch sử dữ liệu để phân tích xu hướng theo thời gian.
- Có gắn nhãn thời gian (Time-variant): Dữ liệu được đánh dấu theo mốc thời


gian, giúp so sánh và phân tích sự thay đổi qua các khoảng thời gian khác nhau

1.1.3 Quy trình xử lý dữ liệu trong Data Warehouse

Dữ liệu được thu thập từ các hệ thống giao dịch và cơ sở dữ liệu khác, sau đó trải qua quá trình làm sạch, chuyển đổi (ETL - Extract, Transform, Load) để đưa vào kho dữ liệu với cấu trúc chuẩn hóa, giúp người dùng dễ dàng truy vấn và phân tích bằng các công cụ BI, SQL client hoặc phần mềm phân tích khác

1.1.4 Các mô hình tiêu biểu của Data Warehouse


- Mô hình Ngôi sao (Star Schema)
 - Đây là mô hình phổ biến nhất trong Data Warehouse.
 - Cấu trúc gồm một bảng sự kiện (fact table) nằm ở trung tâm, chứa các dữ liệu đo lường (ví dụ: số lượng bán, doanh thu).
 - Xung quanh bảng sự kiện là các bảng chiều (dimension tables) chứa thông tin mô tả như thời gian, địa điểm, sản phẩm, chi nhánh.
 - Ưu điểm: Truy vấn đơn giản, nhanh chóng.
 - Nhược điểm: Dữ liệu chiều có thể bị lặp lại, gây dư thừa và tốn bộ nhớ lưu trữ



Hình 1.1.1: Ví dụ về star schema

- Mô hình Bông tuyết (Snowflake Schema)
 - Là biến thể của mô hình ngôi sao nhằm chuẩn hóa các bảng chiều.
 - Các bảng chiều được phân nhánh thành nhiều bảng con nhỏ hơn để giảm sự trùng lặp dữ liệu.
 - Ưu điểm: Giảm dư thừa dữ liệu, lưu trữ hiệu quả hơn.

- Nhược điểm: Cấu trúc phức tạp hơn, truy vấn mất nhiều thời gian hơn do phải liên kết nhiều bảng



Hình 1.1.2: Snowflake Schema

- Mô hình Dữ liệu Đa chiều (Multidimensional Model)
 - Dữ liệu được tổ chức theo các chiều (dimensions) và các chỉ số đo lường (measures).
 - Thường được triển khai trong các hệ thống OLAP (Online Analytical Processing).
 - Có hai kiểu OLAP chính:
 - ROLAP (Relational OLAP): lưu trữ dữ liệu trong cơ sở dữ liệu quan hệ, dùng SQL để truy vấn.
 - MOLAP (Multidimensional OLAP): lưu trữ dữ liệu dưới dạng cấu trúc đa chiều đặc thù, cho phép truy vấn nhanh hơn.


1.1.5 Vai trò và ứng dụng

Data Warehouse giúp doanh nghiệp có cái nhìn tổng quan và sâu sắc về hoạt động kinh doanh, hỗ trợ dự báo xu hướng, cải thiện chiến lược và tối ưu hóa quy trình. Đây là nền tảng quan trọng cho các hệ thống Business Intelligence (BI), phân tích dữ liệu và báo cáo phức tạp, giúp nâng cao hiệu quả quản lý và ra quyết định.

1.2 Tổng quan về quy trình ETL

1.2.1 Giới thiệu

Quy trình ETL (Extract, Transform, Load) là một phương pháp quan trọng trong quản lý và tích hợp dữ liệu, được sử dụng để chuyển dữ liệu từ nhiều nguồn khác nhau vào một hệ thống đích như kho dữ liệu (Data Warehouse) hoặc hồ dữ liệu (Data Lake) nhằm phục vụ cho việc phân tích và ra quyết định.



Hình 1.2.1: ETL Pipeline

1.2.2 Tổng quan về quy trình ETL

1. Extract (Trích xuất dữ liệu)

Đây là bước đầu tiên trong quy trình ETL, dữ liệu được thu thập từ nhiều nguồn khác nhau như cơ sở dữ liệu SQL, hệ thống CRM, file CSV, trang web, hoặc các hệ thống khác. Mục tiêu là lấy toàn bộ dữ liệu cần thiết mà không làm mất mát hoặc thay đổi dữ liệu gốc. Dữ liệu có thể bao gồm cả dữ liệu có cấu trúc và phi cấu trúc.

2. Transform (Chuyển đổi dữ liệu)

Sau khi trích xuất, dữ liệu được xử lý để làm sạch, chuẩn hóa và biến đổi sao cho phù hợp với mô hình dữ liệu của hệ thống đích. Quá trình này có thể bao gồm loại bỏ dữ liệu không hợp lệ, hợp nhất dữ liệu từ nhiều nguồn, chuyển đổi định dạng (ví dụ chuẩn hóa ngày tháng), tính toán lại các giá trị, mã hóa dữ liệu, hoặc các thao tác phức tạp hơn như tổng hợp, lọc, phân loại. Mục đích là đảm bảo dữ liệu đồng nhất, chính xác và dễ sử dụng cho các phân tích tiếp theo.

3. Load (Tải dữ liệu)

Bước cuối cùng là đưa dữ liệu đã được chuyển đổi vào hệ thống đích như kho dữ liệu hoặc hồ dữ liệu. Dữ liệu này sau đó có thể được sử dụng cho các mục đích báo cáo, phân tích kinh doanh, học máy, hoặc các ứng dụng khác. Việc tải dữ liệu có thể diễn ra theo từng đợt định kỳ hoặc theo thời gian thực tùy thuộc vào yêu cầu của hệ thống.

1.2.3 Vai trò và ứng dụng của ETL

- ETL giúp tích hợp dữ liệu từ nhiều nguồn khác nhau, tạo ra một nguồn dữ liệu thống nhất, sạch và có cấu trúc cho việc phân tích.
- Là bước quan trọng trong xây dựng kho dữ liệu (Data Warehouse) và các hệ thống phân tích dữ liệu lớn (Big Data).
- Hỗ trợ các doanh nghiệp trong việc ra quyết định dựa trên dữ liệu chính xác, cập nhật và toàn diện.
- ETL cũng là nền tảng để thực hiện các phân tích nâng cao, dự báo, và các ứng dụng trí tuệ nhân tạo.

1.3 Tổng quan về Web Scraping

1.3.1 Web Scraping là gì ?

Web Scraping là quá trình tự động thu thập dữ liệu từ các trang web bằng cách sử dụng phần mềm hoặc bot để truy cập, phân tích và trích xuất thông tin từ mã nguồn HTML hoặc các thành phần của trang web. Thay vì sao chép dữ liệu thủ công, web scraping giúp lấy dữ liệu nhanh chóng và hiệu quả, đặc biệt hữu ích cho doanh nghiệp, nhà nghiên cứu và nhà phân tích dữ liệu trong việc khai thác thông tin từ Internet.

1.3.2 Cách thức hoạt động

Cách thức hoạt động của Web Scraping:

- Gửi yêu cầu HTTP: Công cụ web scraping gửi yêu cầu truy cập đến trang web mục tiêu, tương tự như trình duyệt khi bạn truy cập trang đó

- Tải trang web và phân tích cấu trúc HTML: Sau khi nhận được phản hồi, công cụ sẽ phân tích mã nguồn HTML để hiểu cấu trúc trang và xác định vị trí dữ liệu cần lấy
- Trích xuất dữ liệu: Dữ liệu được lấy ra từ các phần tử HTML như thẻ, lớp, ID hoặc theo các mẫu cú pháp xác định trước (CSS selectors, XPath)
- Lưu trữ dữ liệu: Dữ liệu thu thập được sẽ được xử lý, làm sạch và lưu dưới dạng có cấu trúc như CSV, JSON hoặc cơ sở dữ liệu để phục vụ phân tích và sử dụng sau này

1.3.3 Ứng dụng của Web Scraping

Ứng dụng của Web Scraping:

- Thu thập dữ liệu thị trường, giám sát giá cả sản phẩm từ các trang thương mại điện tử để phục vụ nghiên cứu và đánh giá cạnh tranh.
- Nghiên cứu và phân tích thông tin từ các trang tin tức, diễn đàn, blog, trang chính phủ nhằm theo dõi xu hướng, ý kiến cộng đồng.
- Tự động cập nhật nội dung, tổng hợp dữ liệu phục vụ sản xuất nội dung mới hoặc báo cáo.

1.3.4 Lưu ý về vấn đề pháp lý

Web scraping cần tuân thủ các quy định và điều kiện sử dụng của trang web. Một số trang web có thể cấm hoặc yêu cầu sự chấp thuận trước khi thu thập dữ liệu. Vi phạm có thể dẫn đến vi phạm bản quyền hoặc chính sách của trang web đó. Ngoài ra, các website cũng có thể áp dụng các biện pháp kỹ thuật để chống lại việc scraping không hợp lệ.

1.4 Tổng quan về BI (Business Intelligence)

1.4.1 BI là gì ?

Business Intelligence (BI) hay còn gọi là trí tuệ doanh nghiệp, là tập hợp các chiến lược, công nghệ, quy trình và ứng dụng được doanh nghiệp sử dụng để thu thập, xử lý và phân tích dữ liệu nhằm hỗ trợ quá trình ra quyết định kinh doanh. BI giúp doanh nghiệp hiểu rõ hơn về quá khứ, hiện tại và dự đoán tương lai thông qua việc chuyển đổi dữ liệu thô thành thông tin có ý nghĩa và dễ tiếp cận



Hình 1.4.1: BI là gì ?

1.4.2 Vai trò và mục tiêu của BI ?

Vai trò và mục tiêu của BI:

- Hỗ trợ ra quyết định: BI giúp doanh nghiệp nhận diện các vấn đề, cơ hội và đưa ra quyết định chiến lược chính xác hơn, từ đó nâng cao hiệu quả hoạt động và tăng lợi nhuận.
- Truy vấn và báo cáo: BI tự động phân tích và xây dựng các báo cáo trực quan, giúp người dùng dễ dàng theo dõi và hiểu dữ liệu tổng quan.
- Phân tích trực tuyến và thống kê: BI cho phép thực hiện các phân tích nhanh, xác định xu hướng và mô hình trong dữ liệu để dự báo và lập kế hoạch.
- Khai thác dữ liệu và dự đoán: BI sử dụng các kỹ thuật khai thác dữ liệu để tìm ra các thông tin giá trị ẩn và hỗ trợ dự đoán tương lai, giúp doanh nghiệp chuẩn bị cho các biến động thị trường.

1.4.3 Thành phần và quy trình hoạt động của BI

- Tích hợp dữ liệu từ nhiều nguồn khác nhau như CRM, chuỗi cung ứng, dữ liệu bán hàng, phân tích tiếp thị, trung tâm cuộc gọi.
- Chuẩn bị và xử lý dữ liệu để phân tích.
- Truy vấn và trực quan hóa dữ liệu qua các bảng điều khiển, báo cáo, biểu đồ.
- Hỗ trợ người dùng đưa ra quyết định dựa trên dữ liệu phân tích được.

1.4.4 Lợi ích của BI

- Tăng khả năng cạnh tranh nhờ ra quyết định dựa trên dữ liệu chính xác.

- Cải thiện hiệu quả hoạt động và tối ưu hóa nguồn lực.
- Giúp doanh nghiệp nhanh chóng thích ứng với thay đổi thị trường và phát hiện cơ hội mới.

Chương 2

Khảo sát đề tài

2.1 Khảo sát nhu cầu

2.1.1 Quy mô tăng trưởng thị trường mỹ phẩm tại Việt Nam

Thị trường mỹ phẩm Việt Nam năm 2023 có giá trị khoảng 2,3 - 2,6 tỷ USD và dự kiến sẽ tăng lên khoảng 2,7 - 4 tỷ USD vào năm 2027, với tốc độ tăng trưởng kép hàng năm (CAGR) khoảng 3,3% - 10-15% tùy nguồn báo cáo.

Số lượng cửa hàng mỹ phẩm tăng nhanh, đặc biệt tập trung tại Hà Nội và TP. Hồ Chí Minh, hai trung tâm kinh tế lớn với nhiều tiềm năng phát triển.

Hơn 90% sản phẩm mỹ phẩm tại Việt Nam là hàng nhập khẩu, chủ yếu từ Singapore, Hàn Quốc, Trung Quốc, Thái Lan và Mỹ

2.1.2 Nhu cầu tiêu dùng và đặc điểm người dùng

- 93% phụ nữ trong độ tuổi 25-32 sử dụng sản phẩm chăm sóc da thường xuyên, đây là nhóm khách hàng tiềm năng nhất với mức chi tiêu trung bình khoảng 700.000 VND/tháng, cao hơn các nhóm tuổi khác.
- Người tiêu dùng có thu nhập càng cao thì chi tiêu cho mỹ phẩm càng nhiều, cho thấy tiềm năng phát triển thị trường lớn ở nhóm khách hàng thu nhập trung và cao.
- Các sản phẩm chăm sóc da được ưa chuộng nhất gồm sữa rửa mặt, nước tẩy trang, kem chống nắng, kem dưỡng ẩm và serum.
- Xu hướng làm đẹp cho nam giới cũng đang tăng trưởng, với thị trường mỹ phẩm dành cho nam giới ước tính đạt khoảng 30 triệu USD và có tốc độ tăng trưởng nhanh

2.1.3 Cạnh tranh và cơ hội

Thị trường mỹ phẩm Việt Nam có sự cạnh tranh gay gắt, với các thương hiệu nước ngoài chiếm phần lớn thị phần nhưng các thương hiệu Việt đang dần khẳng định vị thế bằng chiến lược tập trung vào chất lượng và câu chuyện thương hiệu gần gũi với văn hóa Việt. Hợp tác với các KOL, tận dụng nguyên liệu bản địa và phát triển các sản phẩm thân thiện môi trường là lợi thế cạnh tranh của các thương hiệu nội địa

2.2 Khảo sát nguồn dữ liệu


Các nguồn cung cấp dữ liệu về mỹ phẩm tại Việt Nam bao gồm:

- Báo cáo thị trường và nghiên cứu của các tổ chức uy tín như Nielsen, Statista, Euromonitor, Kirin Capital, Metric, và các báo cáo chuyên sâu từ các công ty nghiên cứu thị trường trong và ngoài nước. Các báo cáo này cung cấp thông tin về quy mô thị trường, phân khúc sản phẩm, xu hướng tiêu dùng, mức chi tiêu của người dân, cũng như dự báo tăng trưởng ngành mỹ phẩm



Hình 2.2.1: Statista là nền tảng dữ liệu và thông tin kinh doanh toàn cầu

- Dữ liệu thương mại điện tử (TMDT) từ các sàn như Shopee, Lazada, Tiki, Sendo, TikTok Shop. Các nền tảng này thu thập và phân tích dữ liệu hàng ngày về doanh số, sản lượng bán, phân khúc giá, thương hiệu, và hành vi tiêu dùng trên các kênh bán lẻ trực tuyến



Hình 2.2.2: Các sàn thương mại điện tử phổ biến tại Việt Nam

- Số liệu nhập khẩu và hải quan Việt Nam cung cấp thông tin chi tiết về giá trị nhập khẩu mỹ phẩm, các loại sản phẩm nhập khẩu phổ biến, thị trường cung ứng chính như Singapore, Hàn Quốc, Trung Quốc, Thái Lan, Mỹ, cũng như xu hướng nhập khẩu theo năm.

2.3 Khảo sát các cách thức thu thập dữ liệu

Thu thập dữ liệu thứ cấp (Secondary Data Collection):

Sử dụng các báo cáo nghiên cứu thị trường, báo cáo phân tích ngành từ các tổ chức uy tín như Nielsen, Statista, Euromonitor, các bài viết chuyên ngành, báo cáo hai quan để lấy dữ liệu đã được tổng hợp sẵn. Phương pháp này tiết kiệm thời gian và chi phí nhưng dữ liệu có thể không hoàn toàn phù hợp với mục tiêu nghiên cứu của thế.

Khảo sát trực tiếp (Primary Data Collection):

Tiến hành khảo sát người tiêu dùng qua bảng hỏi trực tuyến hoặc phỏng vấn trực tiếp để thu thập dữ liệu về hành vi, nhu cầu, sở thích sử dụng mỹ phẩm. Phương pháp này giúp thu thập dữ liệu chính xác, phù hợp mục tiêu nhưng tốn nhiều thời gian và công sức.

Web Scraping

Tự động thu thập dữ liệu từ các trang thương mại điện tử (Shopee, Lazada, Tiki, Sendo), các trang mạng xã hội (Facebook, Instagram, TikTok) hoặc các website chuyên ngành mỹ phẩm để lấy thông tin về sản phẩm, giá cả, đánh giá khách hàng, xu hướng tiêu dùng. Đây là phương pháp hiệu quả để khai thác dữ liệu lớn và cập nhật liên tục.

Phối hợp với các công ty nghiên cứu thị trường

Thuê dịch vụ thu thập dữ liệu chuyên nghiệp theo tiêu chuẩn quốc tế để có dữ liệu chính xác và có chiều sâu phục vụ phân tích và ra quyết định.

So sánh:


Tiêu chí	Thu thập dữ liệu thứ cấp	Khảo sát trực tiếp (Sơ cấp)	Web Scraping (Cào dữ liệu)	Thuê công ty nghiên cứu
Bản chất	Sử dụng các dữ liệu, báo cáo đã có sẵn từ các nguồn khác.	Tự tạo ra dữ liệu hoàn toàn mới bằng cách hỏi trực tiếp đối tượng nghiên cứu.	Tự động trích xuất dữ liệu công khai từ các trang web bằng chương trình máy tính (bot) .	Ủy thác toàn bộ quá trình thu thập và phân tích dữ liệu cho một đơn vị chuyên nghiệp.
Loại dữ liệu thu thập	Dữ liệu tổng hợp, ví mô (quy mô thị trường, tốc độ tăng trưởng, thị phần).	Dữ liệu về thái độ, ý kiến, nhân khẩu học (Tại sao họ mua? Họ thích gì?).	Dữ liệu về hành vi, sản phẩm (Họ thực sự mua gì? Giá bao nhiêu? Đánh giá ra sao?).	Bất kỳ loại nào, thường là sự kết hợp của nhiều phương pháp để có chiều sâu và độ tin cậy cao nhất .
Nguồn dữ liệu	Statista, Euromonitor, Nielsen, các bài báo, báo cáo ngành.	Người tiêu dùng, chuyên gia.	Sàn TMDT (Shopee, Lazada), mạng xã hội, các trang web review.	Mạng lưới respondent, cơ sở dữ liệu độc quyền, khảo sát quy mô lớn.
Chi phí	Thấp đến Trung bình . (Miễn phí từ các báo cáo công khai, hoặc rất đắt cho các báo cáo độc quyền).	Trung bình đến Cao . (Chi phí cho nền tảng khảo sát, quà tặng, thời gian phỏng vấn viên).	Thấp đến Trung bình . (Chi phí thấp nếu tự làm, tăng lên nếu dùng dịch vụ proxy, hạ tầng).	Rất cao . Đây là phương pháp tốn kém nhất.
Thời gian thực hiện	Rất nhanh . Dữ liệu đã có sẵn.	Rất chậm . Cần thời gian thiết kế, triển khai, thu thập và làm sạch.	Nhanh (khi chạy) . Tuy nhiên, thời gian phát triển và bảo trì code có thể đáng kể.	Trung bình đến Chậm . Phụ thuộc vào độ phức tạp của dự án.
Quy mô & Độ lớn	Lớn ở cấp độ thị trường, nhưng thường không chi tiết đến từng sản phẩm/giao dịch.	Nhỏ đến Trung bình . Khó mở rộng quy mô lên hàng triệu người.	Rất lớn . Có thể thu thập hàng triệu điểm dữ liệu một cách dễ dàng.	Linh hoạt , có thể từ các nhóm nhỏ (focus group) đến các khảo sát toàn quốc.
Độ chính xác & Tin cậy	Đáng tin cậy ở mức tổng quan, nhưng có thể lỗi thời hoặc không hoàn toàn phù hợp với mục tiêu cụ thể.	Tính phù hợp cao vì được thiết kế riêng. Tuy nhiên có thể bị sai lệch (thiên kiến) do cách đặt câu hỏi hoặc câu trả lời không trung thực.	Khách quan và chính xác tại thời điểm cào (dữ liệu hành vi thực tế). Nhưng có thể bị ảnh hưởng bởi dữ liệu giả, review ảo.	Rất cao . Được đảm bảo bằng phương pháp luận chuyên nghiệp và các tiêu chuẩn quốc tế.
Yêu cầu kỹ năng	Kỹ năng tìm kiếm, phân tích và đánh giá nguồn tin.	Kỹ năng thiết kế bảng hỏi, thống kê, phỏng vấn.	Kỹ năng lập trình (Python), hiểu biết về HTML/CSS, và các vấn đề pháp lý/dạo đức.	Kỹ năng quản lý dự án và quản lý nhà cung cấp.

Hình 2.3.1: So sánh các cách thức thu thập dữ liệu

2.4 Khảo sát các công cụ thu thập dữ liệu

Công cụ khảo sát thị trường và thu thập ý kiến khách hàng:

SurveyMonkey, Google Forms, Social Mention: Các công cụ khảo sát và phân tích mạng xã hội giúp thu thập dữ liệu về xu hướng, ý kiến người tiêu dùng và phản hồi thị trường



Hình 2.4.1: Google Form để khảo sát dữ liệu

Công cụ thu thập và phân tích dữ liệu thương mại điện tử:

EcomHeat: Nền tảng tự động thu thập và phân tích dữ liệu doanh thu, giá bán, điểm đánh giá của hàng trăm ngàn sản phẩm trên các sàn TMDT lớn như Shopee, Lazada, Tiki, TikTok Shop. Giúp xác định xu hướng sản phẩm bán chạy, phân tích đối thủ và lập kế hoạch kinh doanh



Hình 2.4.2: EcomHeat

Công cụ web scraping và phân tích dữ liệu trực tuyến

Các công cụ web scraping phổ biến như BeautifulSoup, Scrapy, Selenium có thể được sử dụng để tự động thu thập dữ liệu từ trang web thương mại điện tử, mạng xã hội, trang tin tức về mỹ phẩm



Hình 2.4.3: Cào dữ liệu web bằng BeautifulSoup

Các API Public để thu thập dữ liệu

KiotViet Public API: Đây là API dành cho ngành bán lẻ, cho phép truy xuất và quản lý dữ liệu về nhóm hàng, sản phẩm, đơn hàng, hóa đơn, khách hàng, phiếu nhập hàng... Ví dụ, bạn có thể lấy danh sách sản phẩm mỹ phẩm, thông tin tồn kho, giá cả, thuộc tính sản phẩm qua các endpoint API của KiotViet. API này hỗ trợ tích hợp dữ liệu giữa hệ thống quản lý bán hàng và các nền tảng khác như website, thương mại điện tử, CRM

2.5 Khảo sát các định dạng dữ liệu phổ biến

Dữ liệu dạng bảng (Structured data)

Bao gồm thông tin về sản phẩm, khách hàng, đơn hàng, doanh thu, tồn kho, chi phí... được tổ chức theo hàng và cột, dễ dàng quản lý và phân tích. Ví dụ: danh mục sản phẩm với các trường như mã hàng, tên sản phẩm, đơn vị tính, màu sắc, phân nhóm; dữ liệu khách hàng với tên, số điện thoại, địa chỉ, lịch sử mua hàng

Dữ liệu văn bản (Text data)

Bao gồm các tài liệu, hồ sơ công bố sản phẩm, mô tả thành phần, nhãn mỹ phẩm, hợp đồng, báo cáo... thường được lưu dưới dạng file PDF, Word hoặc file văn bản thuần

Dữ liệu hình ảnh và đồ họa

Hình ảnh sản phẩm, nhãn hiệu, logo, thiết kế quảng cáo có thể tồn tại dưới dạng file ảnh (.jpg, .png, .tiff) hoặc file vector (.ai, .eps)


Dữ liệu phi cấu trúc khác

Bao gồm các đánh giá khách hàng, phản hồi, dữ liệu mạng xã hội, video, âm thanh... có thể được lưu trữ và xử lý bằng các công nghệ đặc thù.

2.6 Khảo sát các cách lưu trữ dữ liệu

File Excel và CSV

Là công cụ phổ biến để lưu trữ và quản lý dữ liệu dạng bảng như danh mục sản phẩm, khách hàng, đơn hàng, doanh thu, chi phí, tồn kho. Excel hỗ trợ các tính năng tính toán, lọc, báo cáo và biểu đồ giúp phân tích dữ liệu hiệu quả



Hình 2.6.1: File Excel được sử dụng để lưu trữ dữ liệu

File văn bản và PDF

Dùng để lưu trữ hồ sơ, tài liệu pháp lý, phiếu công bố sản phẩm, báo cáo, hợp đồng... giúp bảo đảm tính toàn vẹn và dễ dàng chia sẻ

Cơ sở dữ liệu (Database)

Dữ liệu được lưu trữ có cấu trúc trong các hệ quản trị cơ sở dữ liệu như SQL Server, MySQL, Oracle, PostgreSQL hoặc NoSQL như MongoDB để quản lý lượng lớn dữ liệu, truy vấn nhanh và bảo mật cao.



Hình 2.6.2: SQL để lưu trữ dữ liệu lớn

Dịch vụ lưu trữ đám mây

Google Drive, Dropbox, OneDrive, Amazon S3... giúp lưu trữ linh hoạt, dễ dàng truy cập và chia sẻ dữ liệu từ nhiều thiết bị và vị trí khác nhau.



Hình 2.6.3: Nền tảng lưu trữ dữ liệu đám mây như Google Cloud

Phần mềm quản lý bán hàng chuyên dụng

Các phần mềm như Nhanh.vn, KiotViet, Haravan, MISA eShop tích hợp lưu trữ và quản lý dữ liệu tổng thể từ sản phẩm, khách hàng đến đơn hàng, tồn kho, doanh thu trên nền tảng trực tuyến, đồng bộ đa kênh.

Bảng so sánh:

Tiêu chí	File (Excel, CSV)	File (PDF, Văn bản)	Cơ sở dữ liệu (Database)	Lưu trữ Đám mây (Cloud Storage)	Phần mềm Quản lý Bán hàng
Bản chất / Loại hình	Tập tin cục bộ, dạng bảng	Tập tin tĩnh, phi cấu trúc	Hệ quản trị CSDL (quan hệ SQL hoặc không quan hệ NoSQL)	Dịch vụ lưu trữ đối tượng/file (Object/File Storage) trên cloud	Nền tảng tích hợp (SaaS) , cung cấp dịch vụ phần mềm
Cấu trúc dữ liệu	Có cấu trúc (Structured) theo hàng và cột.	Phi cấu trúc (Unstructured).	SQL : Cấu trúc chặt chẽ (schema-on-write). -> NoSQL : Bản cấu trúc/Phi cấu trúc (schema-on-read).	Bất kỳ loại nào . Chỉ lưu trữ file/object.	Có cấu trúc (do nhà cung cấp định nghĩa và quản lý).
Trường hợp sử dụng tốt nhất	Phân tích dữ liệu quy mô nhỏ, báo cáo nhanh, nhập/xuất dữ liệu đơn giản.	Lưu trữ tài liệu, hợp đồng, báo cáo, hướng dẫn. Đảm bảo tính toàn vẹn định dạng.	SQL : Hệ thống giao dịch (OLTP), ứng dụng yêu cầu tính nhất quán cao.-> NoSQL : Big Data, ứng dụng web thời gian thực.	Xây dựng Data Lake, sao lưu & phục hồi, lưu trữ tài nguyên web (ảnh, video).	Doanh nghiệp vừa và nhỏ cần giải pháp "tất cả trong một" mà không cần đội ngũ kỹ thuật.
Khả năng mở rộng	Rất thấp . Bị giới hạn bởi tài nguyên máy tính và phần mềm.	Không áp dụng cho việc xử lý dữ liệu.	SQL : Cao (thường là mở rộng dọc - Vertical Scaling).-> NoSQL : Rất cao (thiết kế để mở rộng ngang - Horizontal Scaling).	Gần như vô hạn (Virtually Unlimited).	Phụ thuộc hoàn toàn vào hạ tầng và gói dịch vụ của nhà cung cấp.
Tốc độ truy vấn/xử lý	Thấp đến Trung bình . Rất chậm khi file lớn.	Rất thấp . Phải đọc và phân tích toàn bộ file.	Rất cao . Được tối ưu cho việc truy vấn dữ liệu phức tạp (SQL) hoặc đơn giản (NoSQL).	Phụ thuộc vào kích thước file và API. Không phải là công cụ truy vấn.	Cao . Được nhà cung cấp tối ưu cho các tác vụ nghiệp vụ cụ thể.
Độ phức tạp / Kỹ năng yêu cầu	Thấp . Người dùng cuối có thể sử dụng.	Thấp .	Cao . Yêu cầu kiến thức về quản trị CSDL, ngôn ngữ truy vấn (SQL).	Trung bình . Yêu cầu kiến thức về Cloud và API.	Rất thấp . Giao diện người dùng thân thiện, không cần kỹ năng kỹ thuật.
Điểm mạnh	- Cục kỳ phổ biến, dễ sử dụng.->- Trực quan, linh hoạt cho phân tích nhỏ.	- Bảo toàn định dạng gốc.->- Tính bảo mật cao, khó chỉnh sửa. ->- - Phổ biến để chia sẻ.	- Toàn vẹn dữ liệu (ACID trong SQL).->- Khả năng truy vấn mạnh mẽ.->- An toàn và bảo mật cao.	- Độ bền bỉ rất cao (99.999999999%).->- Chỉ phí lưu trữ cực rẻ.->- Linh hoạt, khả năng mở rộng vô hạn.	- Giải pháp trọn gói, tiện lợi.->- Đồng bộ đa kênh bán hàng.->- Có hỗ trợ kỹ thuật từ nhà cung cấp.
Điểm yếu	- Giới hạn dung lượng.->- Rủi ro về tính toàn vẹn dữ liệu.->- Khó cộng tác và kiểm soát phiên bản.	- Khó trích xuất và phân tích dữ liệu.->- Không phù hợp để lưu trữ dữ liệu động.	- SQL : Kém linh hoạt khi thay đổi cấu trúc.->- NoSQL : Tính nhất quán thường thấp hơn.->- Chỉ phí vận hành và quản trị cao.	- Không phải là CSDL, không thể truy vấn dữ liệu trực tiếp.->- Chỉ phí truy cập và truyền dữ liệu có thể cao nếu sử dụng nhiều.	- Phụ thuộc vào nhà cung cấp.->- Khó tùy biến hoặc tích hợp sâu.->- Chỉ phí thuê bao theo thời gian.
Mô hình chi phí	Thường là trả phí một lần (bộ Microsoft Office) hoặc miễn phí (Google Sheets).	Miễn phí để đọc, trả phí cho các công cụ tạo và chỉnh sửa nâng cao.	Mã nguồn mở : Miễn phí (MySQL, PostgreSQL).-> Thuong mại : Trả phí bản quyền (Oracle, SQL Server).	Pay-as-you-go (trả theo dung lượng lưu trữ, số lượng yêu cầu, băng thông).	Thuê bao (Subscription) hàng tháng hoặc hàng năm.

Hình 2.6.4: Bảng so sánh các công cụ lưu trữ dữ liệu

2.7 Khảo sát các công cụ ETL chuyên dụng

Các công cụ ETL chuyên dụng phổ biến và được sử dụng rộng rãi trong năm 2024-2025 bao gồm:

- Hadoop: Nền tảng mã nguồn mở mạnh mẽ cho xử lý dữ liệu lớn, hỗ trợ phân phối và xử lý dữ liệu trên nhiều máy chủ
- Google Cloud Dataflow: Dịch vụ ETL đám mây của Google, hỗ trợ xử lý dữ liệu theo luồng và theo lô, tích hợp tốt với hệ sinh thái Google Cloud
- Azure Data Factory: Dịch vụ tích hợp dữ liệu đám mây của Microsoft, hỗ trợ tạo, lên lịch và quản lý các pipeline dữ liệu mà không cần nhiều mã hóa
- AWS Data Pipeline & AWS Glue: Dịch vụ ETL của Amazon Web Services giúp tự động hóa di chuyển và chuyển đổi dữ liệu, hỗ trợ xử lý dữ liệu thời gian thực và batch
- Talend: Nền tảng tích hợp dữ liệu mã nguồn mở và thương mại, hỗ trợ tự động hóa quy trình ETL, làm sạch và chuyển đổi dữ liệu
- Apache Airflow: Nền tảng lập lịch và quản lý workflow mã nguồn mở, dùng để xây dựng và điều phối các pipeline ETL phức tạp

Bảng so sánh các công cụ:

Tiêu chí	Hadoop	Google Cloud Dataflow	Azure Data Factory	AWS Glue & Data Pipeline	Talend	Apache Airflow
Bản chất công cụ	Framework mã nguồn mở cho xử lý dữ liệu lớn phân tán (Big Data).	Dịch vụ ETL đám mây (Managed Service), serverless, xử lý cả luồng và lô.	Dịch vụ ETL đám mây (Managed Service), thiên về tích hợp và điều phối (orchestration) trực quan.	Dịch vụ ETL đám mây (Managed Service), serverless. Glue để xử lý, Data Pipeline để điều phối (cũ hơn).	Nền tảng tích hợp dữ liệu (Platform), có cả bản mã nguồn mở và thương mại.	Nền tảng điều phối workflow (Orchestrator) mã nguồn mở.
Trường hợp sử dụng chính	Xử lý các tập dữ liệu cực lớn (terabytes, petabytes) theo lô (batch).	Các pipeline xử lý dữ liệu phức tạp, yêu cầu tự động cơ gián, xử lý cả batch và streaming.	Tích hợp dữ liệu từ nhiều nguồn (on-premise, cloud), xây dựng pipeline bằng giao diện kéo-thả.	Xây dựng Data Lake, ETL serverless, tự động phát hiện schema dữ liệu.	Tích hợp dữ liệu giữa các hệ thống khác nhau, làm sạch dữ liệu với giao diện đồ họa.	Lập lịch, điều phối và giám sát các luồng công việc phức tạp (không chỉ ETL).
Điểm mạnh	- Khả năng mở rộng gần như vô hạn. - Chi phí phần mềm bằng 0 (mã nguồn mở). - Hệ sinh thái mạnh (Spark, Hive, HBase).	- Hoàn toàn Serverless, không cần quản lý máy chủ. - Tự động cơ gián tối ưu. - Mô hình hợp nhất cho cả xử lý batch và stream (Apache Beam).	- Giao diện trực quan (Low-code), dễ sử dụng cho cả analyst. - Hơn 90+ connectors có sẵn. - Tích hợp sâu với hệ sinh thái Azure.	- Serverless Spark/Python, chỉ trả tiền khi chạy. - Glue Data Catalog & Crawler tự động phát hiện schema. - Tích hợp chặt chẽ với S3, Redshift.	- Thư viện connectors khổng lồ. - Giao diện đồ họa (GUI) rất mạnh mẽ. - Tự động sinh mã Java/Spark. - Đa nền tảng (cloud-agnostic).	- "Workflows as Code" (Python), cực kỳ linh hoạt. - Khả năng mở rộng cao, cộng đồng lớn. - Tích hợp được với mọi thứ.
Điểm yếu / Thách thức	- Cực kỳ phức tạp để cài đặt và vận hành. - Yêu cầu kiến thức chuyên sâu về hệ thống. - Không hiệu quả cho dữ liệu nhỏ và truy vấn thời gian thực.	- Chi phí có thể khó đoán do tính chất serverless. - Phụ thuộc vào hệ sinh thái Google Cloud. - "Đường cong học tập" ban đầu với Apache Beam.	- Ít linh hoạt hơn so với các giải pháp code-based như Airflow. - Chi phí có thể tăng nhanh với các pipeline chạy thường xuyên.	- AWS Data Pipeline là công nghệ cũ, ít được khuyến dùng. - Có thể phức tạp khi kết hợp nhiều dịch vụ AWS với nhau. - Khó khăn khi sử dụng ngoài hệ sinh thái AWS.	- Bản miễn phí (Open Studio) có giới hạn về hiệu năng và tính năng công tác. - Bản thương mại có chi phí cao. - Có thể tồn nhiều tài nguyên máy trạm.	- Chỉ là công cụ điều phối, không tự xử lý dữ liệu (cần gọi Spark, BigQuery, v.v.). - Yêu cầu kỹ năng lập trình Python. - Tự quản lý có thể phức tạp.
Đối tượng sử dụng	Kỹ sư dữ liệu (Data Engineer) có kinh nghiệm, các tổ chức lớn.	Data Engineer, nhà phát triển muốn tập trung vào logic thay vì hạ tầng.	Data Engineer, Chuyên viên BI (BI Developer), Data Analyst.	Data Engineer, nhà phát triển làm việc chủ yếu trên AWS.	Data Engineer, Chuyên viên tích hợp dữ liệu (Integration Specialist).	Data Engineer, nhà khoa học dữ liệu (Data Scientist), DevOps.
Mô hình chi phí	Miễn phí (phần mềm), nhưng chi phí hạ tầng và vận hành rất cao.	Pay-per-use (trả theo tài nguyên CPU, memory, storage sử dụng theo giây).	Trả theo số lần pipeline chạy (activity runs), giờ tích hợp dữ liệu (DIU-hours),...	Glue: Pay-per-use (DPU-hour). Data Pipeline: Trả theo tần suất chạy.	Open Studio: Miễn phí. Commercial: Theo đăng ký (Subscription), chi phí cao.	Miễn phí (phần mềm). Chi phí phát sinh nếu dùng các dịch vụ managed (GCP Composer, AWS MWAA).

Hình 2.7.1: Bảng so sánh các công cụ ETL

2.8 Khảo sát các công cụ trực quan hoá dữ liệu

Các công cụ trực quan hóa dữ liệu chuyên dụng phổ biến và hiệu quả nhất:

- Tableau: Giao diện thân thiện, dễ sử dụng. Kết nối đa dạng nguồn dữ liệu (Teradata, SAP, MySQL, AWS, Hadoop). Hỗ trợ tạo biểu đồ, bản đồ, dashboard đa dạng. Cộng đồng hỗ trợ lớn.
- Microsoft Power BI: Hỗ trợ phân tích và trực quan hóa dữ liệu từ nhiều nguồn cục bộ và đám mây. Dễ sử dụng, tích hợp tốt với hệ sinh thái Microsoft. Có phiên bản miễn phí và trả phí
- Google Charts: Miễn phí, dễ tích hợp với các sản phẩm Google. Nhiều loại biểu đồ đa dạng, tương tác cao.

Bảng so sánh các công cụ trực quan hóa dữ liệu:

Tiêu chí	Tableau	Microsoft Power BI	Google Charts
Bản chất công cụ	Nền tảng Business Intelligence (BI) chuyên sâu, tập trung vào khám phá và kể chuyện bằng dữ liệu (Data Exploration & Storytelling).	Nền tảng BI và phân tích kinh doanh toàn diện, là một phần của hệ sinh thái Microsoft Power Platform .	Một thư viện JavaScript miễn phí, dùng để nhúng các biểu đồ tương tác vào các trang web và ứng dụng.
Đối tượng sử dụng chính	Chuyên viên phân tích dữ liệu (Data Analyst), Nhà khoa học dữ liệu (Data Scientist), chuyên gia BI.	Data Analyst, người dùng doanh nghiệp (Business User), chuyên gia tài chính, và bất kỳ ai quen thuộc với Excel.	Lập trình viên Web (Web Developer), nhà phát triển phần mềm cần tích hợp biểu đồ vào sản phẩm.
Xử lý & Mô hình hóa dữ liệu	Tốt. Sử dụng Tableau Prep cho các tác vụ ETL trực quan. Khả năng tính toán trong Tableau Desktop mạnh nhưng cú pháp đôi khi phức tạp.	Xuất sắc. Tích hợp sẵn Power Query (cho ETL) và ngôn ngữ DAX (cho các phép tính phức tạp), đây là một lợi thế cạnh tranh rất lớn.	Không có. Mọi quá trình chuẩn bị và xử lý dữ liệu phải được thực hiện ở phía backend hoặc bằng JavaScript trước khi truyền dữ liệu vào thư viện.
Khả năng trực quan hóa	Xuất sắc. Được coi là tiêu chuẩn vàng về độ mượt mà, tính thẩm mỹ và khả năng tương tác (kéo-thả, lọc, drill-down). Rất mạnh về bản đồ địa lý.	Rất tốt. Cung cấp kho biểu đồ đa dạng và có thể mở rộng vô hạn thông qua Marketplace (custom visuals). Giao diện quen thuộc, dễ dùng.	Tốt. Cung cấp các loại biểu đồ phổ biến (cột, tròn, đường...). Khả năng tùy chỉnh cao nhưng đòi hỏi kiến thức về lập trình JavaScript.
Kết nối dữ liệu	Rất mạnh. Hỗ trợ hàng trăm trình kết nối (connectors) tới file, CSDL (SQL, NoSQL), ứng dụng SaaS, và các dịch vụ đám mây (AWS, Azure, GCP).	Rất mạnh. Tương tự Tableau, nhưng có lợi thế tích hợp sâu và tối ưu hơn với các sản phẩm của Microsoft (Azure Synapse, SQL Server, Fabric).	Hạn chế. Dữ liệu chủ yếu được cung cấp thông qua Google Sheets hoặc được lập trình viên truyền vào dưới dạng đối tượng JavaScript (JSON).
Hệ sinh thái & Tích hợp	Tích hợp sâu với Salesforce . Có cộng đồng người dùng (Tableau Public) cực kỳ lớn để học hỏi và chia sẻ.	Điểm mạnh nhất. Tích hợp liền mạch với Microsoft 365 (Teams, SharePoint, Excel) và Azure , tạo ra một môi trường làm việc cộng tác toàn diện.	Tích hợp hoàn hảo với các sản phẩm của Google và bất kỳ ứng dụng web nào.
Chi phí và Cộng tác	Qua Tableau Server (tự host) hoặc Tableau Cloud . Yêu cầu giấy phép (license) cho cả người tạo và người xem (viewer).	Qua Power BI Service (SaaS). Mô hình chia sẻ linh hoạt qua Workspace, Apps. License Pro cho phép chia sẻ và xem.	Chia sẻ bằng cách gửi URL của trang web. Dữ liệu thường là công khai. Không có cơ chế bảo mật hay quản lý người dùng tích hợp.
Mô hình chi phí	Cao. Tính phí theo loại người dùng (Creator, Explorer, Viewer). Không có phiên bản miễn phí thực sự cho mục đích thương mại riêng tư.	Rất cạnh tranh. Power BI Desktop miễn phí. Bản Pro có chi phí rất hợp lý. Có các gói Premium/Fabric cho doanh nghiệp lớn.	Hoàn toàn miễn phí.
Điểm khác biệt cốt lõi	"Nghệ thuật" trực quan hóa. Tốt nhất cho việc khám phá dữ liệu tự do và tạo ra các dashboard có tính thẩm mỹ cao.	"Sức mạnh toàn diện". Sự kết hợp hoàn hảo giữa khả năng tự phục vụ (self-service), mô hình hóa dữ liệu mạnh mẽ, và chi phí hợp lý.	"Công cụ cho nhà phát triển". Một giải pháp linh hoạt, miễn phí để thêm biểu đồ vào các sản phẩm web, không phải là một công cụ BI độc lập.

Hình 2.8.1: Bảng so sánh các công cụ trực quan hóa dữ liệu

Chương 3

Phân tích và thiết kế hệ thống

3.1 Cách thức thu thập dữ liệu

a. Đối với dữ liệu trên Lazada:

- Ta có thể sử dụng API Public sau để lấy dữ liệu về (Tuy nhiên dữ liệu lấy về chỉ có thể là dữ liệu có trên trang tìm kiếm, không thể lấy các thông tin cụ thể hơn như: bình luận người dùng, mô tả sản phẩm, ...)

- API để lấy dữ liệu có dạng:

BASE_URL + query parameters + trang cào + sản phẩm

Trong đó:

BASE_URL: <https://www.lazada.vn/>

query parameter: `&ajax=true&catalog_redirect_tag=true&isFirstRequest=true`

trang cào: `&page={số trang}` - số trang bắt đầu từ trang 1

sản phẩm: `&q={tên sản phẩm}` - tên sản phẩm cần cào


- Khi ta yêu cầu GET: nếu thành công, dữ liệu trả về sẽ là dạng JSON và trong đó có thông tin các sản phẩm nằm ở trang đó. Nhiệm vụ của chúng ta sau đó sẽ là lấy ra các thông tin đó.

- Dữ liệu của từng sản phẩm của chúng ta sẽ gồm các trường có ích cho việc phân tích như sau:

Thứ tự	Trường dữ liệu	Kiểu dữ liệu
1	name	Chuỗi (String)
2	product_id	Số nguyên (Int)
3	priceShow	Chuỗi (String)
4	rating	Số thực (Float)
5	location	Chuỗi (String)
6	seller_id	Số nguyên (Int)
7	seller_name	Chuỗi (String)
8	brand_name	Chuỗi (String)
9	original_price	Số nguyên (Int)
10	sold_quantity	Số nguyên (Int)
11	review_count	Số nguyên (Int)
12	image_url	Chuỗi (String)
13	item_url	Chuỗi (String)

b. Đối với dữ liệu trên Shopee:

- Do ta không lấy dữ liệu bằng API được (trừ khi phải mua hoặc có tài khoản shopee gắn mác Yêu thích, ...). Vậy nên, ta sẽ sử dụng phương pháp Web Scraping.
- Do Shopee rất nghiêm ngặt trong vấn đề bảo mật dữ liệu của họ. Thế nên việc cào dữ liệu đòi hỏi phải đăng nhập trước thì ta mới có thể truy cập được vào phần tìm kiếm sản phẩm của họ. Các "cửa ải" bạn có thể gặp trước khi có thể đi đến trang tìm kiếm sản phẩm là:
 1. Sau khi đăng nhập bằng tài khoản, hệ thống bắt xác nhận gmail
 2. Sau khi đăng nhập xong, bắt thực hiện captcha. Tuy nhiên thực hiện captcha xong thì báo lỗi



Hình 3.1.1: Captcha Shopee

- Nếu như sau khi bạn thành công vượt qua "cửa ải" captcha. Chúc mừng bạn đã hoàn thành vòng 1, thế nhưng đó mới chỉ là mở đầu. Khi cào dữ liệu các trang (tức là chỉ cào trên trang tìm kiếm), bạn cào khoảng tầm 5-6 trang thì sẽ bắt đầu xuất hiện captcha tiếp
- Việc cào sub-page (tức các trang con của từng sản phẩm) để lấy ra các thông tin như: bình luận, thông tin shop cụ thể, mô tả sản phẩm, ... là khá khó vì Shopee rất nghiêm ngặt. Việc cào khoảng tầm 5-6 subpage thì sẽ lại xuất hiện captcha. Cho thấy tính năng chống bot vượt trội của Shopee
- Thế nhưng, khó không phải là không thể. Mặc dù khó khăn là thế nhưng các dữ liệu trên trang tìm kiếm sản phẩm vẫn cung cấp cho chúng ta một vài thông tin quan trọng như sau:

Thứ tự	Tên trường dữ liệu	Kiểu dữ liệu
1	id	Số nguyên (tự động tăng)
2	ngay_cao	Ngày/Thời gian
3	ma_san_pham	Số nguyên (có thể rỗng)
4	ma_shop	Số nguyên (có thể rỗng)
5	ma_danh_muc	Số nguyên (có thể rỗng)
6	ten_san_pham	Chuỗi văn bản dài
7	loai_san_pham	Chuỗi văn bản dài (có thể rỗng)
8	ten_sp_chinh_xac	Chuỗi văn bản dài (có thể rỗng)
9	gia_ban	Số nguyên (có thể rỗng)
10	giam_gia	Chuỗi văn bản
11	da_ban	Số thực (có thể rỗng)
12	nhân	Chuỗi văn bản
13	uu_dai	Chuỗi văn bản
14	chi_bao_khuyen_mai	Chuỗi văn bản dài
15	danh_gia	Chuỗi văn bản
16	dia_chi	Chuỗi văn bản
17	danh_muc_san_pham	Chuỗi văn bản
18	link	Chuỗi văn bản dài

3.2 Cách thức lưu trữ dữ liệu thô

- Sau khi cào dữ liệu bằng Python, dữ liệu từ cả Shopee và Lazada sẽ được trực tiếp đổ vào 2 bảng trong database.
- Sau khi dữ liệu được cào về 2 bảng này. Trong mỗi bảng sẽ có 1 cơ chế Trigger để tự động đổ vào 1 bảng khác. Bảng này là bảng chứa các trường dữ liệu tồn tại ở cả 2 bảng.

- Cấu trúc bảng của bảng chung như sau:


Thứ tự	Tên trường dữ liệu	Kiểu dữ liệu
1	id	Số nguyên
2	ngay_cao_dlieu	Ngày
3	nguồn_du_lieu	Chuỗi văn bản
4	ma_sp	Chuỗi văn bản
5	ma_shop	Chuỗi văn bản
6	dia_chi_shop	Chuỗi văn bản
7	ten_sp_hien_thi	Chuỗi văn bản
8	gia_hien_thi	Chuỗi văn bản
9	link_sp	Chuỗi văn bản
10	so_sp_da_ban	Chuỗi văn bản
11	danh_gia	Chuỗi văn bản
12	cong_dung_sp	Chuỗi văn bản
13	ten_chinh_xac_sp	Chuỗi văn bản
14	loai_sp	Chuỗi văn bản
15	thuong_hieu_sp	Chuỗi văn bản
16	is_transform	Số nguyên
17	shop_id_platform	Chuỗi văn bản
18	product_id_shop_platform	Chuỗi văn bản

Mặc dù trong bảng này tồn tại 1 vài trường dữ liệu không tồn tại như tôi liệt kê trước đó. Thế nhưng lý do tại sao thì sẽ được giải thích tại phần "Cài đặt hệ thống"

3.3 Phương pháp thực hiện ETL và xây dựng Data Warehouse


- Dùng python lấy dữ liệu từ bảng chung (bảng đệm trước khi thực hiện đưa vào Data Warehouse)
- Thực hiện các phép biến đổi, làm sạch
- Đổ dữ liệu vào các Data Mart trong Data Warehouse (cụ thể là đổ vào SQL Server). Ở đây thiết kế Data Warehouse tôi gợi ý 2 phương pháp

Sử dụng mô hình ROLAP với thiết kế như sau:



Hình 3.3.1: Mô hình ROLAP

Sử dụng Snowflake Schema với thiết kế như sau:



Hình 3.3.2: Snowflake Schema

- Tuy nhiên thì ở đây, để cho đơn giản. Tôi sẽ sử dụng **Snowflake Schema**

3.4 Lập lịch tự động quy trình

Sử dụng python để lập lịch chạy các file python lấy dữ liệu, biến đổi dữ liệu. Có thể sử dụng Task Scheduler trong Windows để làm điều đó.

Chương 4

Xây dựng hệ thống

4.1 Các công nghệ sử dụng

Dựa theo khảo sát như trên, kết hợp với điều kiện về nguồn lực cũng như thời gian. Chúng ta quyết định sẽ triển khai như sau

4.1.1 Nguồn thu thập dữ liệu

Chúng ta sẽ tập trung vào 2 nền tảng thương mại điện tử phổ biến tại Việt Nam chính là: Shopee và Lazada



Hình 4.1.1: Shopee và Lazada là hai nền tảng lớn

Lý do đưa ra ở đây đó chính là:

- Thị phần áp đảo của Shopee và Lazada: Năm 2024, Shopee chiếm 64% thị phần thương mại điện tử Việt Nam, với doanh thu khoảng 197.000 tỷ đồng

(tương đương 9,3 tỷ USD trong quý IV/2024). Lazada, dù giảm thị phần, vẫn giữ 7,6% với doanh thu 6.030 tỷ đồng trong nửa đầu năm 2024. Hai sàn này cùng nhau chiếm hơn 70% thị phần trong số các nền tảng thương mại điện tử lớn, đảm bảo dữ liệu từ đây phản ánh phần lớn thị trường mỹ phẩm trực tuyến

- Doanh thu ngành mỹ phẩm dẫn đầu thị trường: Ngành mỹ phẩm (làm đẹp) là một trong những ngành hàng chủ lực trên Shopee và Lazada. Trong năm 2023, ngành này đạt doanh thu 8.690 tỷ đồng trên các sàn lớn, với 73,4 triệu sản phẩm được bán ra, tăng trưởng 63% so với năm 2022. Shopee và Lazada là hai nền tảng đóng góp chính vào con số này, khiến chúng trở thành nguồn dữ liệu lý tưởng để khảo sát xu hướng mỹ phẩm.

4.1.2 Cách thức thu thập dữ liệu

- Với những trang web cung cấp API Public hoặc dễ dàng đăng ký để nhận "key" cho việc trích xuất dữ liệu bằng API (như Lazada) thì ta có thể sử dụng module trong python như là request, ... để lấy dữ liệu về.
- Tuy nhiên, với các trang web không cung cấp API Public hoặc không dễ dàng đăng ký API (như Shopee), ta sẽ sử dụng cách khác để lấy dữ liệu: Web Scraping bằng cách sử dụng các module trong Python như BeautifulSoup, Selenium, ...

4.1.3 Cách thức lưu trữ dữ liệu thô

Với những dữ liệu thô sau khi được thu thập về (từ cả Lazada và Shopee) thì ta sẽ đưa dữ liệu vào 2 bảng khác nhau trong SQL Server



Hình 4.1.2: SQL Server để lưu trữ dữ liệu thô

4.1.4 Thực hiện ETL

Tiếp tục sử dụng Python trong quá trình ETL (Đồng thời kết hợp cả các truy vấn SQL Server nữa)



Hình 4.1.3: Kết hợp python với sql trong quá trình ETL

4.1.5 Cách thức lưu trữ dữ liệu sau khi xử lý

Sau khi được xử lý, dữ liệu tiếp tục được chuyển đến một Database khác cũng trong SQL Server


4.1.6 Trực quan hoá dữ liệu

Sử dụng Microsoft Power BI để thiết kế dashboard nhằm đảm bảo tính thẩm mỹ và sự linh hoạt trong việc thay đổi dữ liệu trong tương lai



Hình 4.1.4: Power BI

4.1.7 Tóm tắt hệ thống triển khai



Hình 4.1.5: Tóm tắt hệ thống triển khai

4.2 Xây dựng chương trình lấy dữ liệu từ Lazada và Shopee

4.2.1 Chương trình lấy dữ liệu từ Lazada

- Hệ thống bao gồm 4 file tất cả:
 - File config.py: chứa các hằng số để cấu hình như GEMINI_API_KEY, các thông số để kết nối đến cơ sở dữ liệu SQL Server, ...
 - File utils.py: chứa các hàm xử lý các vấn đề trong hệ thống: lưu dữ liệu, trích xuất thông tin, ...
 - File requirements.txt: chứa các module yêu cầu phải cài đặt trước khi chạy chương trình
 - File scraper.py: file chính để chạy chương trình. Thực hiện điều phối chương trình.
- Những cài đặt mà người dùng cần làm trước khi chạy chương trình:
 1. Chỉnh sửa file config.py để điền các thông số riêng của máy bạn. Cụ thể như sau:
 - BASE_URL: giữ nguyên, không cần thay đổi
 - HEADERS: cấu hình headers người dùng ở Lazada. Người đọc có thể hỏi các chatbot.

- DB_CONFIG: Cấu hình cho cơ sở dữ liệu SQL Server. Nếu không phải cơ sở dữ liệu này thì bạn phải sửa lại code. Người đọc có thể hỏi các chatbot
- GEMINI_API_KEY: Danh sách API Key của Google (miễn phí). Cách lấy các bạn có thể tham khảo trên youtube hoặc hỏi chatbot.


2. Chỉnh sửa file scraper.py các thông tin sau:

- list_query: danh sách sản phẩm bạn muốn cào
- pages_begin_scrape: trang bắt đầu muốn cào
- pages_end_scrape: trang cuối cùng muốn cào

● Cách hoạt động của chương trình (Thực thi ở file scraper.py):

- Bước 1: Tạo bảng trong database
- Bước 2: Duyệt qua tất cả các các trang
 - + 2.1: Request GET với API ta đã nói ở trên
 - + 2.2: Duyệt qua từng sản phẩm. Trong từng sản phẩm ta lấy ra các thông tin như đã trình bày
 - + 2.3: Do trường dữ liệu là ít, ta tích hợp thêm mô hình AI của google để trích xuất thêm thông tin từ tên sản phẩm nữa
 - + 2.4: Cuối cùng tất cả dữ liệu lấy được trên trang được lưu vào biến "all_scraped_items"
 - + 2.5: Lưu tất cả dữ liệu đã lấy vào bảng mục tiêu trong SQL Server
- Bước 3: Kết thúc chương trình

Vẽ sơ đồ khối cho chương trình:

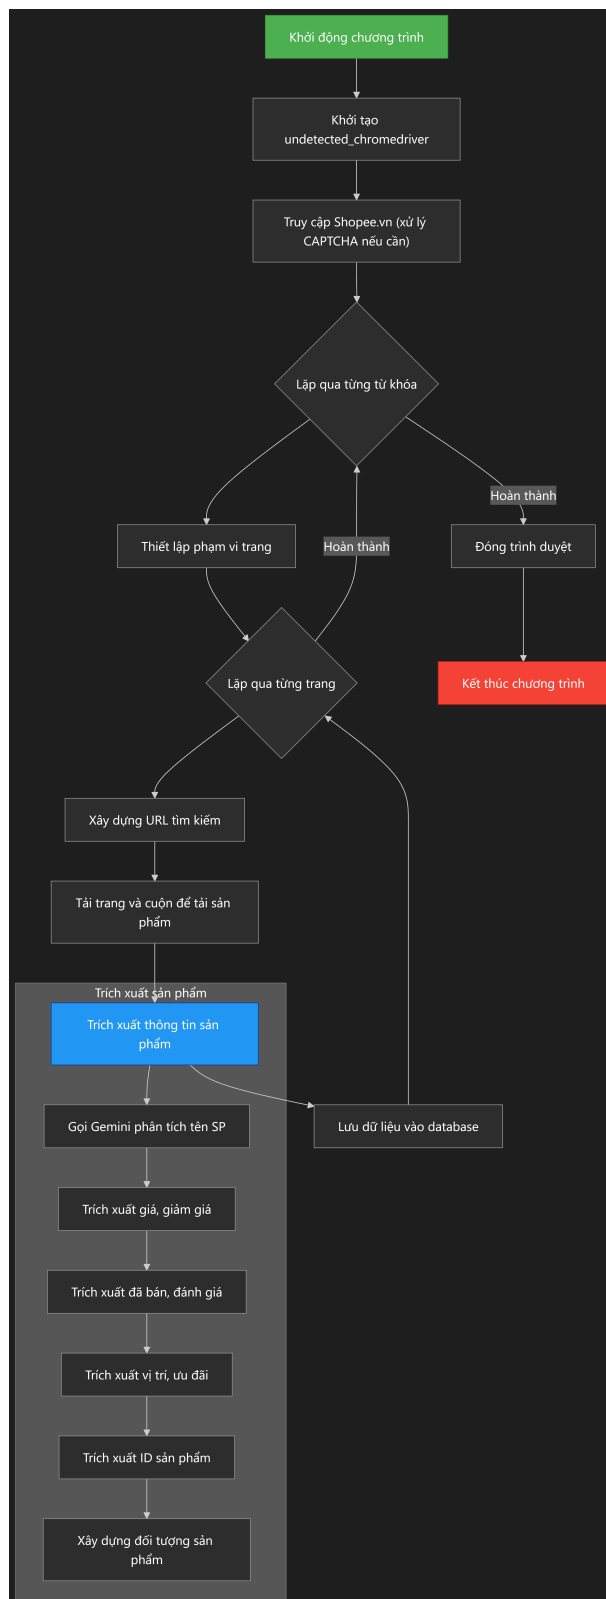


Hình 4.2.1: Sơ đồ khối cho chương trình lấy dữ liệu Lazada

4.2.2 Chương trình lấy dữ liệu từ Shopee

- Hệ thống bao gồm 1 file tất cả:
 - `test_another_ver.py` là bản cập nhật cuối cùng của cào dữ liệu từ Shopee. File này xử lý toàn bộ các tác vụ liên quan đến thu thập cũng như xử lý dữ liệu.
- Những cài đặt mà người dùng cần làm trước khi chạy chương trình:
 1. Lấy API key của google rồi cho vào biến: `GEMINI_API_KEY`
 2. Đọc hàm `crawl_shopee` rồi thay đổi các biến như:
 - `table_name`: tên bảng muốn lưu trong CSDL SQL Server
 - `connection_string`: cấu hình kết nối tới SQL Server
 3. Kéo xuống main, thay đổi các thông tin như:
 - `skincare_product_list`: danh sách các sản phẩm muốn cào
 - `start_page`: trang bắt đầu muốn cào
 - `num_pages`: số lượng trang muốn cào (tính từ trang bắt đầu)
- Cách hoạt động của chương trình:
 - B1: Khởi tạo và Cấu hình
 - B2: Khởi động Trình duyệt
 - B3: Lặp qua các Từ khóa Tìm kiếm:
 - B4: Cào dữ liệu cho từng Từ khóa (`crawl_shopee`)
 - B6: Cào dữ liệu sản phẩm trên trang hiện tại (`crawl_products`)
 - B6: Trích xuất thông tin bằng Gemini (`extract_product_info_with_gemini`)
 - B7: Lưu vào Cơ sở dữ liệu (`save_to_database`)
 - B8: Kết thúc

Vẽ sơ đồ khối cho chương trình:



Hình 4.2.2: Sơ đồ khối cho chương trình Shopee

4.3 Xây dựng cơ chế tự động insert vào bảng chung bằng TRIGGER trong SQL Server

4.3.1 Trigger của bảng Lazada

```
CREATE TRIGGER TR_Lazada_Insert
ON raw_lazada_products
AFTER INSERT
AS
BEGIN
    SET NOCOUNT ON;
    MERGE total_source_data AS T
    USING inserted AS S
    ON (T.ngay_cao_dieu = TRY_CONVERT(DATE, S.crawl_date, 103)
    AND T.nguon_du_lieu = 'Lazada'
    AND T.ma_sp = S.product_id AND T.ma_shop = S.seller_id)
    WHEN NOT MATCHED BY TARGET THEN
        INSERT (ngay_cao_dieu, nguon_du_lieu, ma_sp, ma_shop, dia_chi_shop,
            ten_sp_hien_thi, gia_hien_thi, link_sp, so_sp_da_ban, danh_gia,
            cong_dung_sp, ten_chinh_xac_sp, loai_sp, thuong_hieu_sp)
        VALUES (TRY_CONVERT(DATE, crawl_date, 103),
            'Lazada',
            product_id,
            seller_id,
            location, name,
            priceshow,
            item_url,
            sold_quantity,
            rating,
            product_use_extracted,
            product_name_extracted,
            product_material_extracted,
            brand_name);
END;
```

Hình 4.3.1: Trigger của bảng Lazada

4.3.2 Trigger của bảng Shopee

```
CREATE TRIGGER TR_Shopee_Insert
ON raw_shopee_products
AFTER INSERT
AS
BEGIN
    SET NOCOUNT ON;
    MERGE total_source_data AS T
    USING inserted AS S
    ON (T.ngay_cao_dieu = CAST(S.ngay_cao AS DATE)
    AND T.nguon_du_lieu = 'Shopee'
    AND T.ma_sp = CAST(S.ma_san_pham AS VARCHAR(50))
    AND T.ma_shop = CAST(S.ma_shop AS VARCHAR(50)))
    WHEN NOT MATCHED BY TARGET THEN
        INSERT (ngay_cao_dieu, nguon_du_lieu, ma_sp, ma_shop,
            dia_chi_shop, ten_sp_hien_thi, gia_hien_thi, link_sp, so_sp_da_ban,
            danh_gia, cong_dung_sp, ten_chinh_xac_sp, loai_sp, thuong_hieu_sp)
        VALUES (
            CAST(ngay_cao AS DATE),
            'Shopee',
            CAST(ma_san_pham AS VARCHAR(50)),
            CAST(ma_shop AS VARCHAR(50)),
            dia_chi,
            ten_san_pham,
            CAST(gia_ban AS VARCHAR(200)),
            link,
            CAST(da_ban AS VARCHAR(100)),
            danh_gia,
            cong_dung_chinh,
            ten_sp_chinh_xac,
            loai_san_pham,
            thuong_hieu
        );
END;
```

Hình 4.3.2: Trigger của bảng Shopee

4.4 Xây dựng ETL Pipeline

4.4.1 Tổng quan

Xử lý ETL bao gồm tất cả 5 file:

1. File "config.py": chịu trách nhiệm cấu hình các thông số cố định (các hằng số)
2. File "extract.py": quá trình extract, chịu trách nhiệm lấy dữ liệu từ database ra để xử lý
3. File "transform.py": quá trình transform, chịu trách nhiệm biến đổi và làm sạch dữ liệu.
4. File "load.py": quá trình load, chịu trách nhiệm tải dữ liệu vào Data Warehouse
5. File "main.py": chương trình chính.

4.4.2 Những cài đặt người dùng cần thực hiện

1. Cấu hình "LAKE_SQL_SERVER_CONFIG": liên kết tới bảng chung như ta đã làm ở phần TRIGGER trên
2. Cấu hình "DW_SQL_SERVER_CONFIG": cấu hình tới datawarehouse

4.4.3 Extract: extract.py

1. Hàm "get_lake_db_connection()" Hàm này có nhiệm vụ thiết lập kết nối đến cơ sở dữ liệu SQL Server của Lake. Nó sử dụng thư viện pyodbc và thông tin cấu hình từ LAKE_SQL_SERVER_CONFIG (được import từ file config.py) để tạo chuỗi kết nối.
2. Hàm "extract_data(lake_cursor)": Hàm này dùng để trích xuất dữ liệu từ bảng total_source_data trong cơ sở dữ liệu Lake. Cụ thể, nó chỉ lấy những hàng mà cột is_transform có giá trị bằng 0, tức là những dữ liệu chưa được xử lý.

4.4.4 Transform: transform.py

1. Hàm "clean_cong_dung_sp(value)": Làm sạch và chuẩn hóa chuỗi "công dụng sản phẩm"
2. Hàm "just_capitalize(value)": Viết hoa chữ cái đầu tiên của một chuỗi.

3. Hàm "clean_address(value)": Làm sạch và chuẩn hóa địa chỉ.
4. Hàm "clean_price(value, to_type=float)": Làm sạch và chuyển đổi giá trị giá thành kiểu số (mặc định là float).
5. Hàm "clean_quantity_sold(value, to_type=int)": Làm sạch và chuyển đổi số lượng sản phẩm đã bán thành kiểu số nguyên.
6. clean_rating_score(value, to_type=float): Làm sạch và chuyển đổi điểm đánh giá thành kiểu số (mặc định là float).
7. clean_exact_name(value): Làm sạch tên chính xác của sản phẩm.
8. clean_product_type(value): Làm sạch và chuẩn hóa loại sản phẩm.
9. clean_brand(value): Làm sạch và chuẩn hóa tên thương hiệu.
10. clean_row_data(raw_row_dict): Đây là hàm biến đổi chính, áp dụng tất cả các hàm làm sạch phụ trợ cho một hàng dữ liệu thô duy nhất.

4.4.5 Load: load.py


1. get_dw_db_connection(): Thiết lập kết nối đến cơ sở dữ liệu SQL Server của Kho dữ liệu.
2. create_tables_if_not_exist(dw_cursor): Tạo các bảng trong Kho dữ liệu nếu chúng chưa tồn tại.
3. Các hàm get_or_create__key: Lấy hoặc tạo các khóa cho các bảng chiều (Dim_Brand, Dim_Platform, Dim_Shop, Dim_Date, Dim_Product_Function, Dim_Product).
4. link_product_to_functions(dw_cursor, product_key, function_names_list): Liên kết một sản phẩm với các chức năng của nó trong bảng cầu nối.
5. load_row_to_warehouse(cleaned_row_data, dw_cursor): Tải một hàng dữ liệu đã được làm sạch vào bảng sự kiện Fact_ProductSales trong DWH.
6. update_source_on_success(source_row_id, lake_cursor): Cập nhật cờ cột is transform trong dữ liệu nguồn sau khi xử lý thành công.

4.4.6 Cách hoạt động của chương trình chính

- main_etl_process(): Hàm chính điều phối toàn bộ quy trình ETL.
 - **Kết nối Cơ sở dữ liệu:** Thiết lập kết nối đến Lake Database (nguồn) và Data Warehouse (đích).

- **Tạo bảng DWH:** Gọi hàm `create_tables_if_not_exist` từ `load.py` để đảm bảo các bảng trong Kho dữ liệu đã được tạo.
 - **Trích xuất dữ liệu:** Sử dụng `extract_data` từ `extract.py` để lấy các hàng dữ liệu chưa xử lý từ Lake Database.
 - **Lập và Xử lý từng hàng:**
 - * **Làm sạch dữ liệu (Transform):** Gọi `clean_row_data` từ `transform` để làm sạch và chuẩn hóa từng hàng.
 - * **Tải dữ liệu (Load):** Chuyển dữ liệu đã làm sạch đến DataWarehouse từ `load.py` để chèn vào các bảng chiều và bảng sự kiện trong Kho dữ liệu.
 - * **Cập nhật trạng thái nguồn:** Nếu tải vào DWH thành công, gọi `update_source_on_success` từ `load.py` để đánh dấu hàng dữ liệu nguồn là đã xử lý.
 - **Quản lý giao dịch và Xử lý lỗi:** Đảm bảo tính nhất quán dữ liệu bằng cách `commit` hoặc `rollback` các thay đổi cho từng hàng trên cả hai cơ sở dữ liệu khi có lỗi.
 - **Tổng kết và Đóng kết nối:** In ra bản tóm tắt quá trình và đóng tất cả các kết nối cơ sở dữ liệu.
- Khối `if __name__ == '__main__':` cho phép chạy quy trình ETL độc lập khi file được thực thi trực tiếp.

- Sơ đồ khối



Hình 4.4.1: Sơ đồ khối cho ETL

4.5 Lập lịch chạy tự động bằng Python

Định nghĩa các hàm tác vụ:

- `run_crawl_1()`: Thực thi script `scraper.py`. Đây là tác vụ thu thập dữ liệu từ Lazada.
- `run_crawl_2()`: Thực thi script `test_another_ver.py`. Đây là tác vụ thu thập dữ liệu từ Shopee.
- `run_etl()`: Thực thi script `main.py`. Đây là tác vụ thực hiện quá trình ETL (Extract, Transform, Load) dữ liệu.

Lập lịch các tác vụ:

- `schedule.every().day.at("08:00").do(run_crawl_1)`: Lập lịch chạy tác vụ crawl Lazada hàng ngày vào lúc 8:00 sáng.
- `schedule.every().day.at("08:00").do(run_crawl_2)`: Lập lịch chạy tác vụ crawl Shopee hàng ngày vào lúc 8:00 sáng. Hai tác vụ crawl này sẽ chạy song song.
- `schedule.every().day.at("09:00").do(run_etl)`: Lập lịch chạy tác vụ ETL hàng ngày vào lúc 9:00 sáng, đảm bảo rằng quá trình ETL diễn ra sau khi dữ liệu đã được thu thập.

Vòng lặp chính:

- Một vòng lặp `while True` liên tục kiểm tra và thực thi các tác vụ đã đến thời điểm chạy bằng `schedule.run_pending()`.
- Chương trình tạm dừng 60 giây (`time.sleep(60)`) sau mỗi lần kiểm tra để tránh tiêu tốn tài nguyên hệ thống.


4.6 Thiết kế Dashboard

4.6.1 Phân tích tổng quan thị trường mỹ phẩm trên Shopee theo loại sản phẩm



Hình 4.6.1: Dashboard 1

4.6.2 Phân tích tổng quan thị trường mỹ phẩm trên các sàn theo khu vực



Hình 4.6.2: Dashboard 2

4.7 Toàn bộ code của đồ án

Người đọc có thể tham khảo code tại: https://github.com/thethien8a/Do_An_1

Chương 5

Kết luận

5.1 Kết quả đồ án

Tổng thể đồ án của em đã đạt được một số kết quả sau:

- Lấy được dữ liệu trên trang thương mại điện tử Lazada và Shopee bằng 2 cách: API, Web Scraping
- Xây dựng được Data Warehouse và thiết kế được ETL Pipeline tự động
- Xây dựng được dashboard bằng Power BI
- Tổng hợp những gì đã làm được thành một báo cáo hoàn chỉnh

5.2 Kỹ năng đạt được

- Biết sử dụng DAX trong Power BI
- Biết dùng python web scrape và gọi API
- Biết sử dụng SQL để tổ chức dữ liệu
- Biết một chút về HTML, CSS để hiểu rõ các cấu trúc trang
- Biết sử dụng Power BI
- Biết viết báo cáo bằng Latex
- Biết tham khảo, vận dụng các Chatbot trong nghiên cứu

5.3 Hướng phát triển tương lai

- Sử dụng các công cụ chuyên biệt cho việc thu thập xử lý lưu trữ dữ liệu: Google Cloud, Google Big Query, Apache Airflow, ...
- Xây dựng website
- Sử dụng Docker đóng gói sản phẩm

Tài liệu tham khảo

1. Nguyễn Danh Tú (2023). Slide bài giảng Kho dữ liệu và Kinh doanh thông minh. Khoa Toán - Tin, Đại học Bách khoa Hà Nội.
2. Fundamentals of Data Engineering: Plan and Build Robust Data Systems bởi Joe Reis, Matt Housley
3. Development of an ETL-Pipeline for Automatic Sustainability Data Analysis (June 2023) bởi Hartmut Zadek
4. Data Pipelines Pocket Reference bởi James Densmore